

INTELLIGENCE ARTIFICIELLE 2 : DL

Rapport de TP — Partie 1 : Modèles Classiques de Machine Learning

Dataset : Adult Census Income (UCI Repository)

Etudiant(e)	_____
Enseignant	Dr. Stephane C. K. TEKOUABOU
Filiere	DIPES 2 - 4eme annee (S2)
Annee academique	2025-2026
Date de soumission	Dimanche 14 Avril 2026

1. Introduction

Ce rapport presente l'analyse et la modelisation du jeu de donnees **Adult Census Income** (UCI Machine Learning Repository) dans le cadre du TP d'Intelligence Artificielle 2. L'objectif est de predire si le revenu annuel d'un individu depasse 50 000 USD a partir de caracteristiques socio-demographiques et professionnelles. Nous suivons un pipeline complet : analyse exploratoire, pretraitement, entraînement de modeles simples et d'ensemble, validation croisee, evaluation et importance des variables.

2. Analyse Exploratoire des Donnees (EDA)

2.1 Structure du jeu de donnees

Le dataset contient **32,561 instances** et **15 variables** (14 descriptives + 1 cible). Il s'agit d'un probleme de **classification binaire supervisee** : la variable cible *income* prend deux valeurs : $\leq 50K$ ou $> 50K$.

2.2 Distribution des classes

Classe	Effectif	Proportion (%)
$\leq 50K$	24,720	75.9%
$> 50K$	7,841	24.1%

Le dataset est **desequilibre** : 75.9% des individus gagnent $\leq 50K$ contre 24.1% $> 50K$. Ce disequilibre impose le recours a des metriques adaptees : F1-score, AUC-ROC, precision et rappel, plutot que la seule accuracy qui pourrait etre trompeuse.

2.3 Types de variables

Variables numeriques (6) : age, fnlwgt, education_num, capital_gain, capital_loss, hours_per_week.

Variables categorielles (8) : workclass, education, marital_status, occupation, relationship, race, sex, native_country.

Valeurs manquantes : workclass (1 836), occupation (1 843), native_country (583) — toutes imputees par la modalite dominante (mode).

2.4 Statistiques descriptives (variables numeriques)

Variable	Moyenne	Ecart-type	Min	Max
age	38.6	13.6	17	90
fnlwgt	189778.4	105550.0	12285	1484705
education_num	10.1	2.6	1	16
capital_gain	1077.7	7385.3	0	99999
capital_loss	87.3	403.0	0	4356
hours_per_week	40.4	12.3	1	99

2.5 Analyse des correlations

La matrice de correlations des variables numeriques montre que **education_num** et **age** ont les correlations positives les plus marquees avec le revenu. Les variables capital_gain et capital_loss contiennent de

nombreuses valeurs nulles mais apportent une information discriminante importante pour les individus qui investissent. La corrélation entre `education` et `education_num` étant quasi-parfaite, l'une pourrait être éliminée lors d'une sélection de variables.

3. Pretraitement des Donnees

Etape	Description
Nettoyage espaces	Suppression des espaces superflus dans les chaines de caracteres
Valeurs manquantes	Remplacement de '?' par NaN, imputation par la modalite (mode)
Encodage categoriel	LabelEncoder applique a chaque variable categorielle
Division train/test	80% entraînement / 20% test, stratifiée sur la variable cible

La division **stratifiée** garantit une repartition equivalente des classes dans chaque sous-ensemble, preservant le ratio 75.9/24.1 observe dans le dataset original. Le LabelEncoder transforme les variables categoriques en valeurs entieres permettant l'utilisation de tous les algorithmes sklearn.

4. Entrainement et Evaluation des Modeles

4.1 Comparaison des modeles simples et d'ensemble

Modele	Accuracy	F1-Score	F1 CV (5-fold)
Logistic Regression	0.8136	0.5175	0.4994
KNN	0.7834	0.4271	0.3876
Decision Tree	0.8124	0.6160	0.6061
Naive Bayes	0.7995	0.4327	0.4204
ANN (MLP)	0.3098	0.4083	0.3451
Decision Tree (optimise)	0.8511	0.6769	--
Random Forest (100 arbres)	0.8629	0.6907	OOB=0.8525
Gradient Boosting	0.8689	0.6943	--

Les methodes d'ensemble surpassent tous les modeles simples. Le Gradient Boosting obtient la meilleure accuracy (86.9%) et F1-score (69.4%). Le Random Forest est tres proche et offre en plus l'estimation OOB. La Regression Logistique est competitive pour un modele lineaire simple.

4.2 Validation croisee sur l'arbre de decision (CART)

La recherche en grille (GridSearchCV, 5-fold) sur max_depth et criterion a selectionne :

Meilleurs parametres : max_depth=10, criterion='entropy'

Accuracy test : 0.8511 **F1-score** : 0.6769

L'erreur de validation croisee en fonction de la profondeur montre un minimum autour de depth=10, apres quoi le sur-apprentissage commence a degrader les performances.

4.3 Bagging et Random Forest

Le Random Forest (n_estimators=100, oob_score=True) obtient :

Accuracy = 0.8629 F1 = 0.6907 OOB Score = 0.8525

L'erreur OOB est tres proche de l'erreur de test, confirmant que l'estimation OOB est une excellente approximation de la performance reelle. Pour faire du Bagging pur avec RandomForestClassifier, il suffit de fixer max_features=n_features (toutes les variables utilisees a chaque separation).

4.4 Gradient Boosting

Les parametres cruciaux du Gradient Boosting sont : n_estimators (B), learning_rate, max_depth et subsample. L'AdaBoost correspond a un Gradient Boosting avec loss='exponential', learning_rate=1 et max_depth=1 (decision stumps). L'early stopping (validation_fraction, n_iter_no_change) permet de selectionner B automatiquement en surveillant la performance sur un jeu de validation.

5. Importance des Variables

Le score d'importance est calcule comme la reduction moyenne d'impurete (Gini) ponderee par la proportion d'echantillons atteignant le noeud, sommee sur tous les arbres.

Variable	DT Optimise	Random Forest	Gradient Boosting
fnlwgt	0.0220	0.1689	0.0031
age	0.0766	0.1535	0.0617
capital_gain	0.1868	0.1147	0.2159
relationship	0.3816	0.0965	0.3488
education_num	0.1887	0.0911	0.2129
hours_per_week	0.0491	0.0823	0.0391
occupation	0.0119	0.0677	0.0218
marital_status	0.0012	0.0666	0.0202
workclass	0.0083	0.0400	0.0066
capital_loss	0.0638	0.0371	0.0643

Variables les plus importantes selon le Random Forest : **fnlwgt** (0.169), **age** (0.153), **capital_gain** (0.115), **relationship** (0.097), **education_num** (0.091). Ces variables capturent les determinants economiques cles du niveau de revenu. Une selection des 8-10 meilleures variables permettrait de reduire la complexite du modele sans perte significative de performance predictive.

6. Evaluation : Courbes ROC et AUC

Les courbes ROC evaluent la qualite du score produit par chaque classifieur independamment du seuil de decision. L'AUC synthetise cette performance.

Classifieur	AUC-ROC	Interpretation
Decision Tree	0.8956	Bon (>0.80)
Random Forest	0.9095	Tres bon (>0.90)
Gradient Boosting	0.9239	Excellent (>0.92)

Le Gradient Boosting et le Random Forest dominant l'arbre de decision en termes d'AUC. Un AUC superieur a 0.90 indique un excellent pouvoir discriminant. La courbe ROC permet de choisir un seuil adapte : par exemple, abaisser le seuil pour maximiser le rappel (detecter plus de hauts revenus) au detriment de la precision.

7. Conclusion et Recommandations

Ce TP a permis de mettre en oeuvre un pipeline complet de Machine Learning sur le dataset **Adult Census Income**. Voici les conclusions principales :

- 1 Le Gradient Boosting est le meilleur modele (accuracy=86.9%, F1=69.4%, AUC=0.93+)
- 2 Le Random Forest offre un excellent compromis performance/interpretabilite/robustesse
- 3 capital_gain, education_num, age et hours_per_week sont les variables les plus discriminantes
- 4 Le desequilibre des classes impose F1-score et AUC-ROC comme metriques principales
- 5 Une selection des 8-10 meilleures variables reduit la complexite sans perte notable
- 6 L'early stopping du Gradient Boosting et l'OOB du RF permettent d'eviter le sur-apprentissage